Input : $B \times 3 \times S \times S$

$Q = BS^2$

$S \in \{32, 48 \dots 512\}$

$B \in \{1, \dots, 256\}$

FLOPs | $F_{linear} = 2BN_{in}N_{out} + BN_{out}$

$F_{conv} = 2BH^2_{out}C_{out}C_{in}k^2$

Layer	Вход	# Param	FLOPs
Conv1 7×7, 3→32, s2	8Q	4704	2352Q
MaxPool 3×3, s2	2Q	0	0
Conv2 5×5, 32→64	4Q	51200	6400Q
Conv3 3×3, 64→128, s2	2Q	73728	2304Q
Conv4 1×1, 128→256	4Q	32768	1024Q
Conv5 3×3, 256→256, s2	Q	589824	4608Q
Conv6 1×1, 256→512	2Q	131072	~~100~~ 1024Q
Global Avg Pool	512B	0	2Q
Linear1 512→256	256B	131328	262400B
Linear2 256→100	100B	25700	51300B

Global Avg Pool : $\left(\frac{S}{16}\right)^2 - 1$ сложений

и 1 деление на канал: $F_{avg} = 512B\left(\frac{S}{16}\right)^2 =$
$= 2Q$

$F = 17712Q + 2Q + (262400 + 51300)B$

$\Rightarrow \quad F(S,B) = 17714\,\underset{\overset{\shortparallel}{Q}}{BS^2} + 313700B$

Memory

$N_w = \sum$ параметров из таблиц $=$
$= 1040324, \quad M_w = 4N_w = 4161296$ байт

Исходный Input 3Q хранится весь проход.

	Память, байт
Исходный Input, FP32	$4 \cdot 3Q$
Вход MaxPool, FP32	$4 \cdot 8Q$
Выход MaxPool, FP32	$4 \cdot 2Q$
Временные индексы MaxPool Int64	$8 \cdot 2Q$

$$M(S,B) = M_w + 12Q + 32Q + 8Q + 16Q = 4161296 + 68\,\underset{Q}{\underset{\parallel}{BS^2}}$$ бай

Bytes moved

$D_{conv/linear} = 4(N_x + N_y + N_w)$

$D_{ReLU} = 8N$

6 Conv	$148Q + 3533184$
6 ReLU после conv	$168Q$
MaxPool	$4 \cdot 8Q + 4 \cdot 2Q + 8 \cdot 2Q = 56Q$
Global AvgPool	$8Q + 2048B$
Linear1	$3072B + 525312$
ReLU после Linear1	$2048B$
Linear2	$1424B + 102800$

$$D(S,B) = 4161296 + 380\,\underset{Q}{\underset{\parallel}{BS^2}} + 8592B$$ байт

Latency

P – FLOPs / сек

W – байт / сек

t_0 – время запуска $\equiv$ const

$$t_{compute,i} = \frac{F_i}{P} \qquad t_{memory,i} = \frac{D_i}{W}$$

$$T(S,B;\theta) = t_0 + \sum_{i=1}^{17} \max\left(\frac{F_i(S,B)}{P}, \frac{D_i(S,B)}{W}\right),$$

$$\theta = (\hat{t}_0, \hat{P}, \hat{W})$$

где 17 – кол-во операций, F_i, D_i из таблицы.

$$I_i = \frac{F_i}{D_i}, \quad I_i > \frac{P}{W} \Rightarrow \text{compute-bound}$$

$$< \frac{P}{W} \Rightarrow \text{memory-bound}$$

Energy

$$E(S,B;\Theta_E) = E_0 + P_{base}\,T(S,B;\theta) + e_F\,F(S,B) + e_D\,D(S,B)$$

E_0 – Дж, P_{base} – Вт, e_K – $\frac{\text{Дж}}{\text{FLOP}}$

e_D – Дж/байт

$$E(S, B) = E_0 + P_{base}\,T(S, B) +$$

$$+ e_K(177714 BS^2 + 313700 B) +$$

$$+ e_D(4161296 + 380 BS^2 + 8592 B)$$

$$\theta_E = (E_0, P_{base}, e_K, e_D, \theta)$$